DataCity Analytics

Ciência de Dados Aplicada à Mobilidade Urbana — Parte 2

Relatório técnico • Estudo de Caso II

UNIVAP — Ciência da Computação / Engenharia da Computação

Nova Esperança (cidade fictícia) • Outubro de 2026

Relatório elaborado a partir da execução local informada pelo aluno, dos indicadores compartilhados e dos quatro gráficos exportados. Os registros são sintéticos e não representam medições reais.

1. Introdução e objetivos

A cidade fictícia de Nova Esperança enfrenta desafios relacionados a atrasos, distribuição de passageiros e ocorrências no transporte coletivo. O DataCity Analytics integra dados sintéticos armazenados no MongoDB a consultas Python/PyMongo, preparação com Pandas e visualização com Matplotlib. O objetivo é transformar registros de viagens em indicadores úteis ao planejamento urbano.

Questões investigadas: diferenças de atrasos entre regiões, evolução diária, distribuição de adiantamentos e atrasos, relação entre atrasos e avaliações, capacidade dos veículos e diferenças entre dias úteis e fins de semana.

2. Arquitetura e modelagem

Fluxo implementado: geração sintética em Python → MongoDB local (datacity_db) → consultas com PyMongo → DataFrames Pandas → verificação e tratamento de dados → indicadores → quatro gráficos Matplotlib e exportações. O código é organizado em módulos de configuração, repositórios, serviços e visualizações.

Coleções: linhas (identificador, nome, região, tipo e atividade); veiculos (identificador, linha, capacidade e acessibilidade); viagens (data, hora, linha, veículo, região, passageiros, duração, atraso, avaliação e ocorrência); ocorrencias (referência à viagem, tipo, gravidade e descrição). Referências lógicas ligam as coleções. Datas são tratadas como datas; a hora é campo separado.

3. Geração e qualidade dos dados

A base gerada contém 50 linhas, 500 veículos, 20.000 viagens e 5.000 ocorrências: 25.550 documentos. A análise considera 19.999 viagens após limpeza de uma duplicidade lógica. Antes do tratamento foram identificados um valor ausente de passageiros, um de avaliação, um horário inválido, uma duração inválida e um registro com passageiros impossíveis.

Foram sinalizados 703 casos de lotação acima da capacidade antes da limpeza e 702 depois. Também foram encontrados 3.472 adiantamentos: atrasos negativos podem representar viagens adiantadas, não erros. As regras de validação devem considerar a capacidade de cada veículo e evitar excluir antecipações legítimas.

4. Indicadores gerais

Indicador	Resultado
Viagens após limpeza	19.999
Passageiros médios por viagem	37,08
Duração média	42,18 min
Atraso médio / mediano	7,53 / 7,00 min
Avaliação média	3,87 / 5
Correlação atraso × avaliação	-0,633

Indicador	Resultado
Viagens acima da capacidade	702

5. Visualizações e interpretação

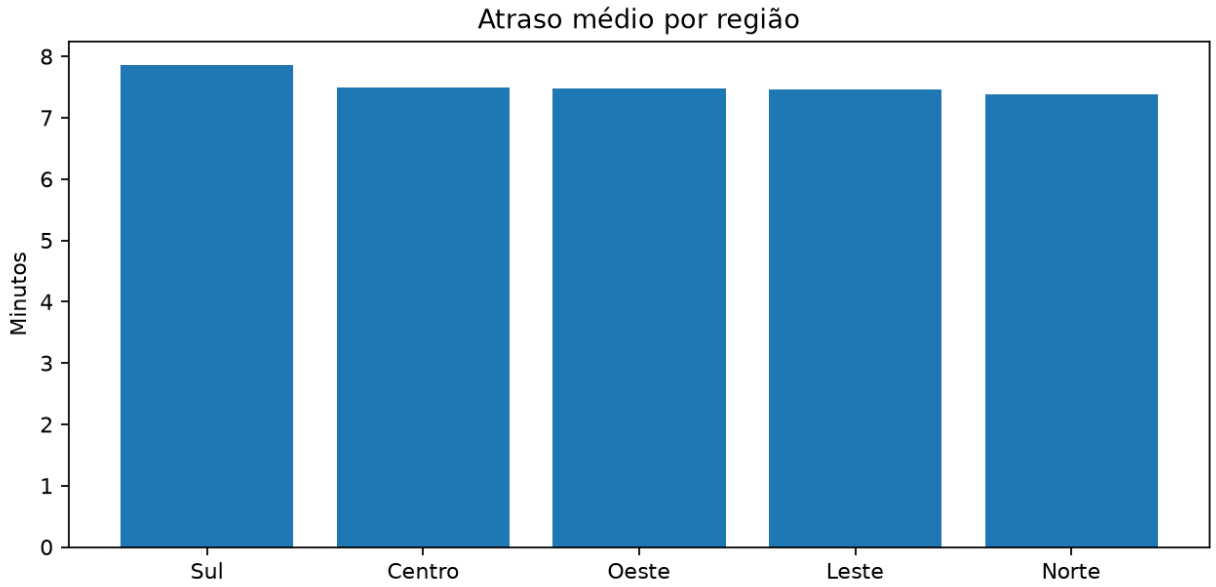


Figura 1 — A região Sul apresenta a maior média (aprox. 7,8 min); Norte, a menor (aprox. 7,4 min). Diferenças pequenas exigem validação com dados reais antes de decisões.

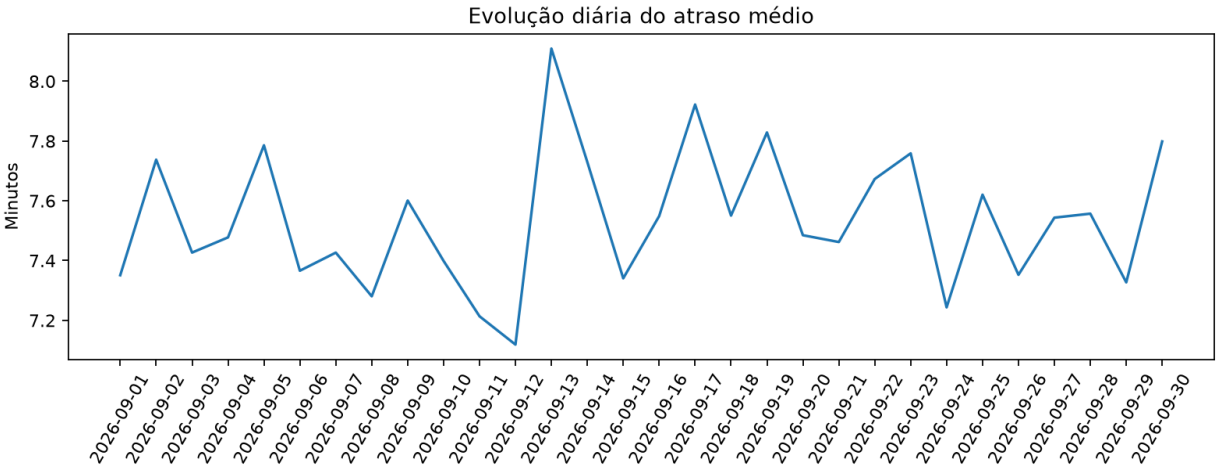


Figura 2 — Em setembro de 2026, o atraso médio diário oscilou aproximadamente entre 7,1 e 8,1 minutos, sem tendência sustentada claramente visível.

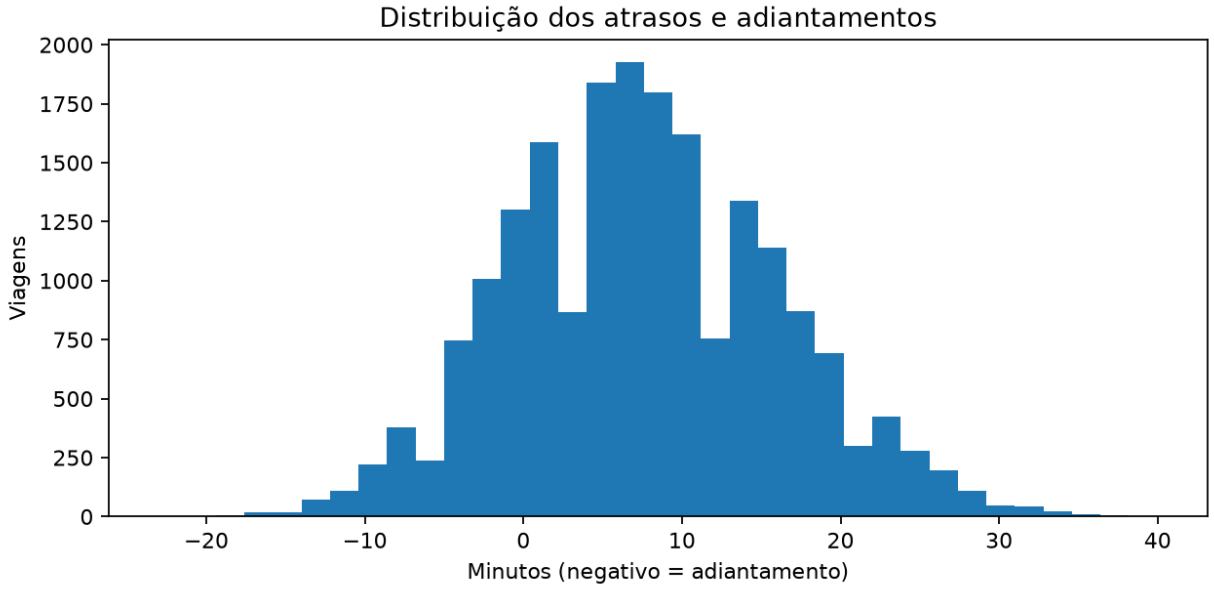


Figura 3 — Distribuição de atrasos e adiantamentos. O centro da distribuição está em atrasos positivos; valores negativos indicam antecipações.

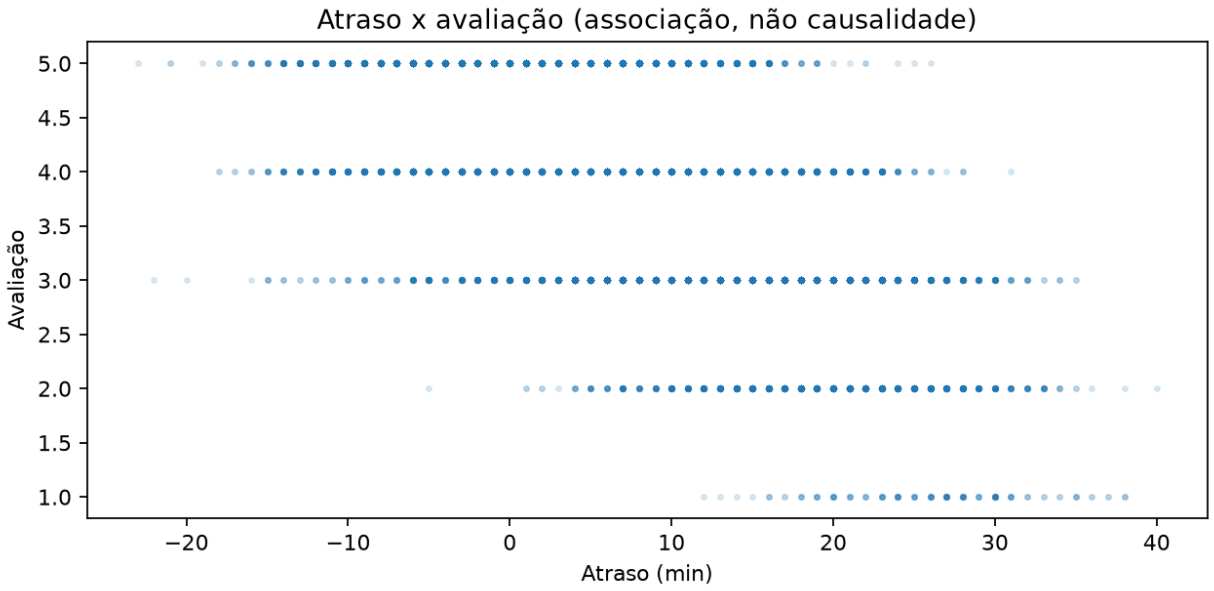


Figura 4 — Relação negativa entre atraso e avaliação, coerente com r = -0,633. Associação estatística não comprova causalidade.

6. Três perguntas analíticas adicionais

Acessibilidade: veículos acessíveis recebem demanda diferente? A proposta é cruzar viagens e veículos e comparar médias de passageiros por acessibilidade; o resumo disponibilizado não traz os valores dessa comparação, portanto não é possível concluir.

Finais de semana: atraso médio de 7,57 minutos em fins de semana versus 7,52 nos demais dias. A diferença é de apenas 0,05 minuto e, isoladamente, não demonstra diferença relevante.

Lotação e avaliação: viagens acima da capacidade tiveram média 3,68, versus 3,88 nas demais. A diferença sugere associação, sem estabelecer causa.

7. Decisões propostas e pirâmide DIKW

Decisão 1: investigar as linhas da região Sul e testar ajustes de horário. Dados: atraso por viagem; informação: média regional maior; conhecimento: necessidade de estudar os corredores críticos; decisão: piloto de revisão operacional.

Decisão 2: avaliar redistribuição de veículos em períodos de maior demanda. Dados: passageiros e capacidade; informação: 702 viagens acima da capacidade; conhecimento: possíveis pontos de sobrecarga; decisão: revisar oferta por faixa horária após validação.

Decisão 3: acompanhar atrasos e satisfação em painel periódico. Dados: minutos e avaliações; informação: correlação negativa; conhecimento: pontualidade pode estar associada à experiência; decisão: monitorar melhorias sem pressupor causalidade.

8. Limitações, ética e LGPD

Cinco limitações principais: (1) base sintética, sem representatividade real; (2) regras de geração podem introduzir relações artificiais; (3) ausência de informações externas de trânsito, clima e infraestrutura; (4) análise agregada pode esconder diferenças por linha e horário; (5) correlações e comparações descritivas não identificam efeitos causais.

Não foram utilizados identificadores pessoais reais de passageiros. Em uma implantação real, seriam necessários minimização de dados, controle de acesso, finalidade explícita, retenção adequada e medidas de segurança em conformidade com a LGPD.

9. Conclusão

O projeto demonstra a cadeia de ciência de dados, da geração e armazenamento até a limpeza, análise e visualização. A execução local relatada confirma as coleções, os indicadores e os quatro gráficos. As recomendações são hipóteses de melhoria para a cidade fictícia, que dependeriam de validação com dados operacionais reais.

Referências

UNIVAP. Atividade Prática Multidisciplinar: DataCity – Ciência de Dados Aplicada à Mobilidade Urbana (Parte 2). Enunciado fornecido na disciplina, 2026.

DataCity Analytics. Exportação resultados.json e quatro gráficos gerados localmente pelo projeto, outubro de 2026.